

文章编号:1001-7372(2018)01-0001-10

# 基于卷积神经网络的路表病害识别与测量

沙爱民, 童 峥, 高 杰

(长安大学 公路学院, 陕西 西安 710064)

**摘要:**为进一步提高利用二维图像统计路面病害的精度与效率,将卷积神经网络(Convolutional Neural Network, CNN)技术引入了基于图像分析的路面病害识别与测量。首先,将原始图像进行等尺寸分割作为CNN的训练样本。其次,经结构设计、前反馈算法训练及样本测试3个步骤后,建立病害识别模型(CNN1)。用训练完成的CNN1对所有图像进行病害类型识别并将输出结果作为裂缝特征提取模型(CNN2)和坑槽特征提取模型(CNN3)的训练样本。采用相同步骤建立裂缝特征提取和坑槽特征提取模型,完成训练后,运行CNN2, CNN3对路面裂缝与坑槽图像进行特征提取。最后,分析图像分辨率对3个CNN识别和特征提取精度以及效率的影响。结果表明:CNN1可以准确识别多种病害, CNN2的裂缝长度提取的平均误差为4.27%,宽度提取的平均误差为9.37%,裂缝病害严重等级判断准确率为98.99%;CNN3的单张图像中的坑槽个数测量无误差,单个坑槽面积的平均误差为13.43%,坑槽病害等级判定准确率为95.32%,可见CNN具有较高的测量精度;CNN1在使用CPU的情况下测试完成原始图像平均用时为704 ms·幅<sup>-1</sup>, CNN2用时为5 376 ms·幅<sup>-1</sup>,采用图形处理器加速后CNN1用时为192 ms·幅<sup>-1</sup>, CNN2测试平均用时为1 024 ms·幅<sup>-1</sup>,可见CNN在图形处理器加速下效率具有显著优势,相比其他方法,在图像分辨率高于70像素时, CNN对路面裂缝与坑槽的识别与测量具有运算高效、结果精准等优势。

**关键词:**道路工程;路面病害;卷积神经网络;路面裂缝;图像测量

中图分类号:U416.2

文献标志码:A

## Recognition and Measurement of Pavement Disasters Based on Convolutional Neural Networks

SHA Ai-min, TONG Zheng, GAO Jie

(School of Highway, Chang'an University, Xi'an 710064, Shaanxi, China)

**Abstract:** In order to further improve the precision and efficiency of pavement disasters using two-dimensional images, convolutional neural network (CNN) was introduced to recognize and measure pavement disasters. First, pavement images were divided into equal-sized maps, which were used as training samples of disaster recognition CNN. Then disaster recognition CNN1 was established by the structural design, before-feedback algorithm and sample tests. Subsequently, all equal-sized maps were input into well-trained disaster recognition CNN1, and the results were used as training samples of crack feature extraction model CNN2 and pit slot feature extraction model CNN3. Meanwhile, the crack feature extraction model CNN2 and the pit slot feature extraction model CNN3 were established with the same procedures. Afterwards, the pavement crack and images of pit slot were extracted by well-trained CNN2 and CNN3. Last but not least,

收稿日期:2017-01-07

基金项目:“十二五”国家科技支撑计划项目(2014BAG05B04);交通运输部建设科技项目(2014 318 223 010)

作者简介:沙爱民(1964-),男,安徽宣城人,教授,博士研究生导师,工学博士, E-mail:ams@chd.edu.cn.

the influences of image resolution ratio on the CNN recognition, precision of feature extraction, and efficiency were analyzed. The results show that various pavement disasters can be accurately recognized by CNN1 and the average errors of crack length and crack width of CNN2 are 4.27% and 9.37% respectively. The accuracy rate of crack disease severity level is 98.99%. There is no error of the number of pit slot CNN3, and the average error of each pit slot area is 13.43%. The accuracy rate of pit slot disease severity level is 95.32%. Thus CNN systems show high accuracy. The disaster recognition CNN1 and feature extraction CNN2 for testing original images in CPU conditions take up to  $704 \text{ ms} \cdot \text{sheet}^{-1}$  and  $5\,376 \text{ ms} \cdot \text{sheet}^{-1}$  on average, whilst the disaster recognition CNN1 and feature extraction CNN2 for testing images after the acceleration by graphics processor in GPU conditions take up to  $192 \text{ ms} \cdot \text{sheet}^{-1}$  and  $1\,024 \text{ ms} \cdot \text{sheet}^{-1}$  on average. Thus CNN systems present high efficiency in GPU condition. Compared with other methods, CNN presents high accuracy and efficiency in recognition and measurement of cracks and pit slot when image resolutions are higher than 70 dpi.

**Key words:** road engineering; pavement disaster; convolutional neural network; pavement crack; image measurement

## 0 引言

准确的路面病害检测结果可为路面养护管理决策提供可靠、有效的技术支持。其中,公路路面的裂缝及坑槽病害对路面服役状况具有极为重要的影响,其检测结果很大程度上影响着路面养护时机并决定了所需的养护技术手段。一般认为,传统的人工病害检查常受到主观性判断的影响,存在较大的误差且检测效率低下。因此,借助采集到的路面图像进行病害自动识别和特征测量用于路表损伤分析是目前路面质量检测领域的主流手段。

基于图像分析的路面病害检测始于 1990 年<sup>[1]</sup>,该技术经 20 余年发展取得了长足进步,涌现出诸多路面病害图像识别和特征提取算法,如自动阈值分割法、空域边缘检测法、基于小波分析的裂缝检测法,但也存在对设备要求高、操作复杂、受光线与阴影影响大等缺点<sup>[2-6]</sup>。Luo 等<sup>[2]</sup>开发了实时裂缝测量系统,可以在高速行驶的情况下收集和识别裂缝信息,但由于该系统需要超级计算机辅助计算,对设备要求过高。曹建农等<sup>[3]</sup>采用中值转换的方法实现了路面裂缝损伤自动识别和特征测量,但其操作过程复杂,难以实现快速的批量检测。李清泉等<sup>[4]</sup>使用最小代价路径搜索算法进行裂缝检测,该方法虽然准确性高,但易受光线的影响。Li 等<sup>[5]</sup>使用 F\* Seed-growing 算法进行路面病害的特征提取,该方法假设路面中颜色较深的部分为裂缝,使得结果易受阴影影响,而部分裂缝会被自动忽略,严重影响检测精度。沈照庆等<sup>[6]</sup>使用支持向量机进行路面影像损伤跨尺度识别,该算法提高了路面破损图像识别

的精度和效率,能快速准确地识别出路面损伤的程度和范围,但无法区分路面病害类型。综上可知,路面病害作为一种非线性检测目标,其图像分析方法主要面临 3 个挑战:①背景复杂多变、斑点噪声强、目标信噪比低;②目标与背景之间对比度低;③目标像素的空间连续性差。因此,一般的病害特征提取方法只能得到路面病害的部分信息,很难获得全面的结果。

随着计算技术的发展,卷积神经网络(CNN)被广泛运用于图像识别领域<sup>[7-10]</sup>。CNN 是由 Lecun 等<sup>[11-13]</sup>提出的一种神经网络结构,其是一种高度非线性映射,可将输入图像中目标特征以特定形式输出。因此,如果将 CNN 运用于道路检测领域,那么所采集的路面图像便能直接作为输入数据输入神经网络中,可避免传统算法中复杂的数据预处理。同时,CNN 对于目标几何形状的缩放、倾斜具备高度的鲁棒性,足以应对具有复杂形态的裂缝、坑槽等病害<sup>[14-15]</sup>。此外,CNN 具备强大的背景噪声滤波能力<sup>[16-17]</sup>,足以克服路面检测图像中的斑点噪声及低对比度问题。Tong 等<sup>[18-19]</sup>采用卷积神经网络对沥青路面裂缝进行了自动识别,结果表明,与其他传统检测算法相比卷积神经网络具有良好的稳定性。Tong 等<sup>[20]</sup>利用卷积神经网络对沥青路面的探地雷达图像进行了反射裂缝的识别、定位、测量和三维重建。然而,目前鲜有见直接将路面图像作为输入样本,并借助 CNN 来分析检测路面裂缝与坑槽病害的研究。

因此,尝试将 CNN 引入基于图像分析的路面

病害识别与测量,以期实现准确、自动、实时地判定路面病害种类及严重程度。本文共设计 3 种 CNN,分别用于病害识别(CNN1)、裂缝特征提取(CNN2)和坑槽特征提取(CNN3)。首先,对所采集的路面图像进行简单的预处理并作为 CNN1 训练样本。其次,经结构设计、前反馈算法训练及样本测试 3 个步骤后,建立 CNN1。之后,将训练完成的 CNN1 输出结果作为 CNN2 和 CNN3 的训练样本。相似地,经结构设计、前反馈算法训练及样本测试 3 个步骤后建立 CNN2 和 CNN3。

## 1 图像采集与预处理

### 1.1 采集设备与方法

图 1 所示为本文研究的主要内容与流程,共分为准备、试验及分析 3 个部分。

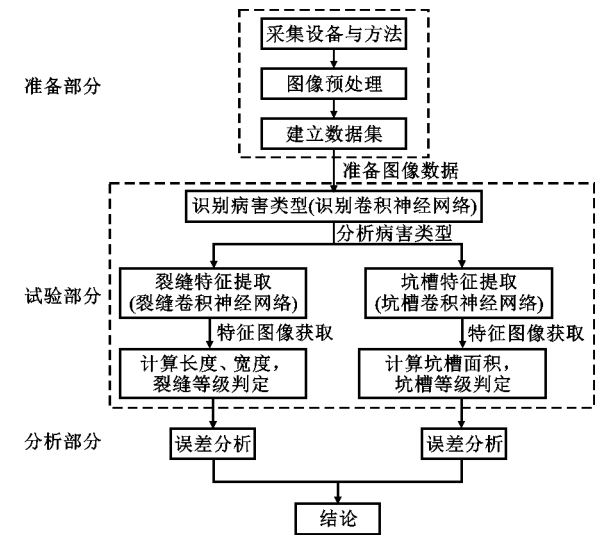


图 1 CNN 系统工作流程  
Fig.1 Workfolw of CNN System

准备部分的核心是进行图像的准备和数据集的建立。为确保数据集具有足够的多样性,所使用的路面图像采集自山西省境内的 4 条高速公路(每条高速拍摄图像 50 张,共 200 张),分别为平阳高速、候平高速、太旧高速、太佳高速。为确保神经网络的识别与测试结果不受光线的影响,图像采集分别选择在光线良好及光线不佳拍摄。为避免拍摄角度及拍摄距离对病害识别与测量准确性的干扰,采集设备镜头应与路面保持垂直,镜头到路面的距离保持不变,具体设备参数如图 2 所示。在数码相机镜头至路面距离为 200 cm 情况下,该设备可清晰拍摄的路面范围为 382 cm×382 cm,略大于单个车道横断面宽度,确保了对 1 个车道实现覆盖。此外,由于车道以外的标线、路缘石等对象的几何特征与坑槽、裂缝具有显著差异,CNN 可自行对其进行区分,因此无需对此类对象进行专门处理。




图 2 图像采集设备  
Fig.2 Device for Image Capturing

### 1.2 图像预处理与数据集的建立

考虑到硬件条件原始图像色彩信息被删除,并按 CNN1 的输入层要求分割为 512 像素×512 像素的图片,如图 3 所示。




图 3 图像预处理  
Fig.3 Image Pre-processing

200 张原始图像被分割成 12 800 张尺寸为 512 像素×512 像素的图像。该 12 800 张图像被作为 CNN 训练和检测的数据集。为评价神经网络的识

别精度,将人工统计的病害数量作为参照。通过人工统计,12 800 张图片中包括无病害图像 3 059 张,裂缝病害图像 5 102 张,坑槽病害图像 4 639 张,其

中 824 张图像同时包含裂缝和坑槽病害。为保证 CNN 病害识别的鲁棒性,从上述 4 条公路中另获取其他病害 512 像素×512 像素的图像 1 200 张,包括泛油、车辙、拥包和油污。

## 2 CNN 的建立与运行

CNN 是一种人工神经网络结构,目前主要用于人脸特征点提取和车辆、行人的定位<sup>[21-22]</sup>。CNN 对于物体形状特征的提取和分析不易受到物体翻转、倾斜和位移的影响,因此被广泛运用于包括二维和三维图像识别<sup>[23-25]</sup>。CNN 的精度与效率足以应对裂缝、坑槽等二维病害外形多变的问题。本文设计了 3 种 CNN 分别用于路面病害类型的识别、裂缝的特征提取和坑槽的特征提取。其中,每种 CNN 模型的建立过程相同(图 4),其主要包括 CNN 的结构设计、训练和测试。本文工作环境是中央处理器为 CPU i7-6700,内存 16 GB,图形处理器为 GPU GTX1060-6GD5。CNN 在 Caffe 开源框架下实现。

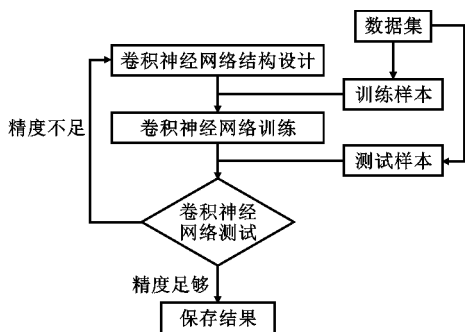


图 4 CNN 的建立流程

Fig. 4 Process of Developing a CNN

### 2.1 病害识别

#### 2.1.1 CNN1 设计

在路面图像中,裂缝、坑槽与正常沥青路面具有显著几何形状区别,因此不同病害图像能依据其形状特征被 CNN1 分类。

##### (1) 样本准备

从上述数据集中随机选取 500 张无病害图像、500 张裂缝病害图像、500 张坑槽病害图像、200 张坑槽与裂缝共同存在的病害图像及 200 张其他病害图像作为训练样本。该 1 900 张图像对应的病害类型作为训练样本的目标样本。目标样本采用正交化编码,其中无病害路面编码为 $[1,0,0,0,0]$ ,裂缝病害编码为 $[0,1,0,0,0]$ ,坑槽病害编码为 $[0,0,1,0,0]$ ,坑槽与裂缝共同存在情况编码为 $[0,0,0,1,0]$ ,其他病害图像编码为 $[0,0,0,0,1]$ 。

此外,剩余图像作为测试样本。

##### (2) CNN1 结构设计

CNN1 的结构设计是为了确定其基本结构。CNN1 由 1 个卷积层 C1,1 个池化层 S1,2 个全连接层 F1 和 F2 组成(图 5),图 5 中数字单位为像素。卷积层的功能是对图像进行特征提取。在卷积层中输入图片被卷积核进行卷积,然后通过激活函数 Sigmoid 得到输出特征矩阵。10 个卷积核拥有不同的权值和阈值,可得到的输出特征矩阵各不相同,如病害的各种特征信息,单个卷积核的卷积操作如式(1)所示。CNN1 中共有 10 个卷积核,每个卷积核尺寸为 $[3,3]$ ,共能提取获得图像中的 10 种特征。池化层的功能是对卷积层获得不同特征矩阵进行聚合统计,避免过多特征进入后续计算,出现过拟合的问题。式(2)为池化操作的运算原理。其中, $D(\cdot)$ 表示一个下采样函数。本文采用最大池化操作函数,使得池化后的特征矩阵在 2 个维度上都缩小 2 倍。全连接层的功能是将池化后的特征与正交编码后的病害类别矩阵建立映射关系。




图 5 CNN1 结构

Fig. 5 Structure of CNN1

式(1)~(3)可表示为

$$x_j^l = f\left(\sum x_j^{l-1} W_i^l + b_i^l\right) \quad (1)$$

$$x_j^{l+1} = \beta_j^l D(x_j^l) \quad (2)$$

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3)$$

式中: $l$  为神经网络结构层数; $j$  为输入灰度图的编号; $x_j^{l-1}$  为神经网络第  $l$  层的第  $j$  张输入灰度图; $W_i^l$  为神经网络第  $l$  层第  $i$  个卷积核的权值矩阵; $b_i^l$  为神经网络第  $l$  层第  $i$  个卷积核的阈值矩阵; $\beta_j^l$  为池化操作的乘性阈值矩阵; $f(x)$  为激活函数。

##### (3) CNN1 的训练

CNN 的一个重要优势是其具有很强的学习能力,表现为寻找训练样本与目标样本的映射关系,该映射关系的确定通过 CNN 的训练来实现。CNN 的训练主要工作是调整 CNN 的权值和阈值。本文采用前反馈算法来调整权值和阈值。

前反馈算法的机理是使用正向传播和反向误差

传播原理来减少 CNN 输出结果和目标结果的误差<sup>[20]</sup>。CNN1 的目的是减少输出的病害类型结果和目标结果之间的误差。前反馈算法基本流程如图 6 所示。首先,随机选取上述准备完成的训练样本中的 30 张图片输入 CNN1。然后,前反馈算法赋予 CNN1 随机的初始权值与阈值。前反馈算法将根据初始权值、阈值和网络结构产生 30 张图片的神经网络计算结果。最后,对比输出的病害结果和目标结果(图像实际对

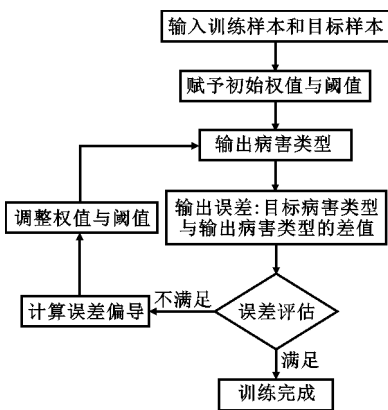


图 6 前反馈算法流程

Fig. 6 Flow of Feed-forward Algorithm

应的病害类型)计算误差。根据前反馈算法的误差,权值和阈值将会根据式(4)进行调节。式(4)中第 1 项代表中误差,反映了输出结果和目标结果之间的差距。式(4)中第 2 项为正则项,用于减少权值与阈值的范围来防止过拟合。 $J(W, b)$ 中权值  $W$  和阈值  $b$  的梯度可以根据式(5)、(6)来进行计算,其中  $f(x)$  的导数如式(7)所示。1 次上述参数调整工作称为 1 次迭代计算。完成 1 次迭代后,再将这 30 张训练样本输入神经网络,进行神经网络训练结果评价,使用均方误差  $M$  对神经网络输出结果进行评价, $M$  根据式(8)进行计算。在此神经网络训练过程中,根据《公路技术状况评定标准》(JTG H20—2007)中对于裂缝和坑槽病害的识别精度要求,认为  $M < 0.05$  且趋于稳定时神经网络训练完成。若  $M$  不满足上述要求则再随机选取训练样本中 30 张图片输入 CNN 重复迭代过程,直至输出结果满足要求。式(4)~(8)可表示为

$$J(W, b) = \frac{1}{30} \sum_{j=1}^{30} J[W, b, (x^{(j)}, y^{(j)})] + \frac{\epsilon}{2} \sum_{l=1}^{10} \sum_{a=1}^3 \sum_{b=1}^3 (W_{ab}^l)^2 \quad (4)$$

$$W_{ab}^{l'} = W_{ab}^l - \alpha \frac{\partial}{\partial W_{ab}^l} J(W, b) \quad (5)$$

$$b^{l'} = b^l - \alpha \frac{\partial}{\partial b^l} J(W, b) \quad (6)$$

$$f'(x) = \frac{e^{-x}}{(1 + e^{-x})^2} \quad (7)$$

$$M = \frac{1}{m} \sum_{i=1}^m (O - T)^2 \quad (8)$$

式中:  $(x^j, y^j)$  为训练样本中第  $j$  张灰度图;  $W_{ab}^l$  和  $W_{ab}^{l'}$  分别为神经网络第  $l$  层的  $W$  矩阵中第  $a$  行第  $b$  列迭代计算前、后的值,  $b^l$  和  $b^{l'}$  分别为神经网络第  $l$  层的  $b$  矩阵中第  $b$  列迭代计算前、后的值;  $\epsilon$  为权衡控制参数;  $\alpha$  为学习率;  $O$  为 CNN1 输出的病害识别结果;  $T$  为测试的目标结果。

#### (4) CNN1 的测试

$M < 0.05$  且趋于稳定仅代表神经网络对于 1 900 张训练样本的输出结果准确,不能完全保证病害识别 CNN 的输出精度。因此,使用未参加训练图像作为测试样本检测训练完成的 CNN1 的识别能力。测试结果用  $M$  来评估,按式(8)计算。这些图像测试样本输出结果的  $M < 0.05$  则可以认定 CNN1 具有较好的病害识别能力。

最后使用测试合格的 CNN1 对所有 12 800 张图片进行病害识别,并将不同类别的病害图像进行分类,分类后获得的裂缝、坑槽图像将分别作为后续的特征提取 CNN 的训练样本。

#### 2.1.2 识别结果分析

图 7 为训练阶段中每次迭代对应的  $M$ 。由图 7 可见,经 100 次迭代训练后,  $M$  从 0.537 降至 0.013 68。前 40 次迭代  $M$  存在明显波动,这是由于每次迭代随机选择的 30 张样本存在个体差异,个体差异存在的误差导致单次迭代的参数调整并不一定使神经网络向目标映射的方向发展,但是整体的迭代趋势向目标映射发展。第 70 次迭代完成后  $M = 0.048 1$ ,满足  $M < 0.05$  的要求。由于本文采用随机梯度下降,单次迭代仅使用 30 张图片进行计算,为避免个体差异造成的偶然情况,迭代次数应延长至 CNN1 持续输出稳定的预期结果。 $M$  在第 65 次至第 100 次迭代中保持稳定,满足  $M$  保持稳定的要求。




图 7 迭代次数与识别精度的关系

Fig. 7 Relation Between Iteration Times and Accuracy of Recognition



训练完成后,将剩余未参加训练的图像直接输入训练后的 CNN1,将输出结果与实际图像上对应的病害进行比较。结果表明:CNN1 可以无误差地识别裂缝、坑槽和两者混合病害,但是识别其他病害时存在错误。测试样本中 1 200 张其他病害图像,其中有 104 张被错误的分类至无病害情况下,主要是油渍污染等病害特征无法很好的在灰度图像中得到体现。虽然这种分类错误并不影响后续裂缝和坑槽的特征提取,但是在今后的研究中应考虑油渍污染等对识别准确性的影响。

## 2.2 病害特征提取与测量

### 2.2.1 特征提取全 CNN 设计

CNN 被广泛用于人脸等形状的特征提取<sup>[26-28]</sup>,此性能可以扩展用于路面检测图像中病害形状的特征提取。本文尝试采用全 CNN 对图片中的病害轮廓进行提取。

#### (1) 样本准备

完成 CNN2 和 CNN3 的设计分别需要拥有特定标记(精确到像素点的病害轮廓)的数据集。数据集制作过程如图 8 所示,主要流程包括原始图像的分割与编号和分割图像的轮廓标记。共所获得的 39 200 张 256 像素×256 像素的图像,其中 11 325 张图像含有裂缝,12 333 张图片含有坑槽。随机选择 1 200 张裂缝图像,1 200 张坑槽图像作为训练样本进行手工标记病害轮廓。手工标记病害轮廓的图像作为训练样本的目标。剩余图像作为测试样本。

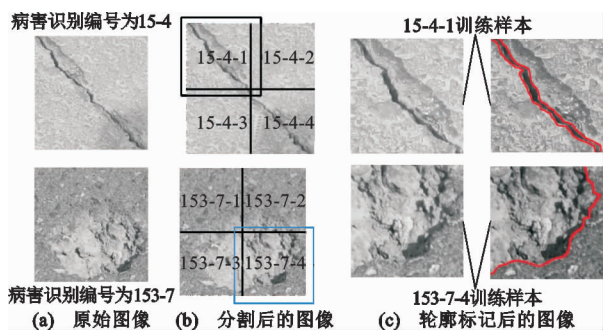


图 8 样本准备

Fig. 8 Sample Preparation

#### (2) CNN2 和 CNN3 结构设计

CNN2 和 CNN3 与 CNN1 最大的区别在全连接层被反卷积层代替。反卷积层可以通过上采样保证输出图片的分辨率,减少了卷积层的卷积算法对图像分辨率的影响。同时,反卷积层可以将特征提取结果直接以图像的形式展现出来,免去了复杂的图像后处理操作。CNN2 和 CNN3 结构相同,结构细节如图 9 所示。




图 9 CNN2 和 CNN3 结构

Fig. 9 Architecrure of CNN2 and CNN3

#### (3) CNN2 和 CNN3 的训练

CNN2 和 CNN3 的训练目的是将病害特征准确地进行提取。特征提取训练结果的误差采用病害区域边界坐标的输出结果与手工提取区域边界坐标的偏差来评价,1 次迭代使用 100 张训练样本图片。根据《公路技术状况评定标准》(JTG H20—2007),沥青路面裂缝和坑槽病害的测量精度选定  $M < 0.1$  且趋于稳定时神经网络训练完成。

#### (4) CNN2 和 CNN3 的测试

$M < 0.1$  且趋于稳定仅代表神经网络对于训练样本的输出结果精确,不能完全保证 CNN2 和 CNN3 的精度。为保证准确性,使用未做标记的测试样本检测 CNN2 和 CNN3 特征提取能力。

#### (5) 裂缝、坑槽混合图像处理

病害识别过程中存在裂缝、坑槽混合图像。将此类图像先后输入 CNN2 和 CNN3,分别提取 2 种病害的特征。

### 2.2.2 特征提取结果分析

图 10 为训练阶段中迭代次数与识别精度的关系。由图 10 可见,训练过程中 CNN2 的  $M$  从 0.437 8 降至 0.056 9,前 400 次迭代存在明显下降趋势,在第 600 次迭代后趋于稳定。CNN3 的  $M$  从 0.993 8 降至 0.084 7,前 750 次迭代  $M$  存在明显下降趋势,之后  $M$  趋于稳定。为避免个体差异造成的偶然情况,迭代次数应延长至 CNN2 和 CNN3 持续输出稳定的预期结果。训练完成后进行测试,部分测试结果如图 11 所示,结果指出特征提取效果良好。

为进一步验证特征提取 CNN2 和 CNN3 的精度,根据特征提取获得的病害轮廓,分别采用感兴趣区域提取和灰度值区分法测量裂缝长度和坑槽面积,并依据《公路技术状况评价标准》(JTG H20—2007)判定病害等级。最后按编号将分割图像拼接成原图,部分结果如表 1,2 所示。




图 10 迭代次数与特征提取精度的关系

Fig. 10 Relation Between Iteration Times and Accuracy of Feature Extraction

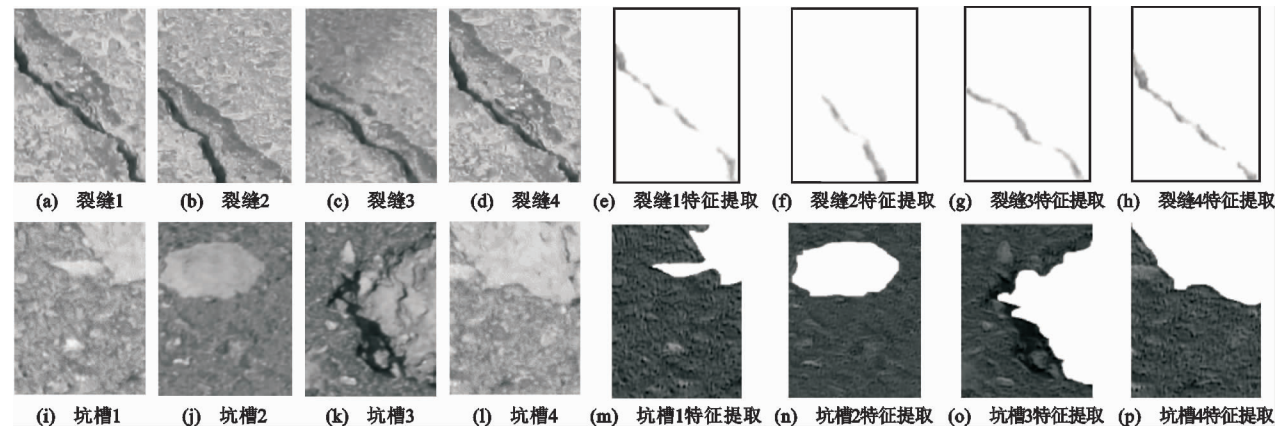


图 11 特征提取部分结果

Fig. 11 Part Results of Feature Extraction



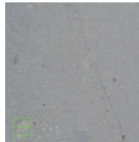

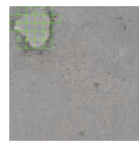
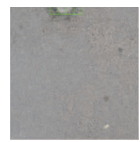
表 1 裂缝计算部分结果

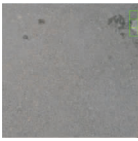

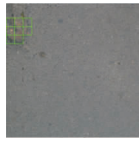
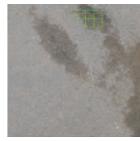


编号	裂缝 1	裂缝 2	裂缝 3	裂缝 4	裂缝 5	裂缝 6
特征提取结果						
类别	纵向裂缝	横向裂缝	横向裂缝	横向裂缝	横向裂缝	网状裂缝
长度/cm	395.706	253.169	397.473	224.268	409.197	558.192
宽度/mm	1.120	2.519	1.306	2.127	2.239	2.519
病害等级	轻	重	轻	重	重	重
长度误差/%	3.74	4.32	6.34	3.95	4.38	3.82
宽度误差/%	7.32	4.37	10.42	4.32	3.75	3.41

编号	裂缝 7	裂缝 8	裂缝 9	裂缝 10	裂缝 11	裂缝 12
特征提取结果						
类别	纵向裂缝	横向裂缝	纵向裂缝	横向裂缝	横向裂缝	纵向裂缝
长度/cm	423.398	408.252	280.572	126.518	497.822	71.785
宽度/mm	4.928	4.928	1.222	1.400	1.399	1.381
病害等级	重	重	轻	轻	轻	轻
长度误差/%	4.83	7.32	4.52	2.38	2.38	6.38
宽度误差/%	2.37	3.32	7.32	8.32	8.32	12.32

表 2 坑槽计算部分结果

Tab. 2 Part Calculation Results of Pit Slots

编号	坑槽 1	坑槽 2	坑槽 3	坑槽 4	坑槽 5	坑槽 6
特征提取结果						
坑槽个数	1	1	1	2	1	不足 1 个
面积/cm <sup>2</sup>	1 772. 119	902. 468	1 138. 724	209. 525;282. 403	6 833. 033	946. 326(图上)
误差/%	7. 82	15. 34	14. 54	11. 43;7. 89	6. 38	5. 98
病害等级	重	轻	重	轻	重	单张图片无法判定

编号	坑槽 7	坑槽 8	坑槽 9	坑槽 10	坑槽 11	坑槽 12
特征提取结果						
坑槽个数	不足 1 个	1	不足 1 个	1	1	1
面积/cm <sup>2</sup>	709. 745	2 157. 067	1 721. 015	612. 329	403. 580	1 925. 125
误差/%	11. 89	6. 38	14. 73	16. 32	9. 86	14. 87
病害等级	单张图片无法判定	重	轻	轻	轻	轻

### 3 CNN 的效率与精度

路面检测的效率和精度至关重要。因此,在上述模型的基础上分析了图像分辨率对计算效率和准确性的影响。路面图像采集受到检测车行驶速度、光照条件等因素限制,其分辨率常常会低于 300 像素。因此,重点对分辨率为 300,150,100,70,50,30 像素的样本进行训练和测试。

#### 3.1 CNN 效率分析

CNN 训练时采用 GPU 加速,测试时采用 GPU 加速测试和 CPU 测试对比,将 CNN1, CNN2, CNN3 的效率和 SVM 识别法<sup>[6]</sup>、中值转换法<sup>[3]</sup>、最小代价路径搜索法<sup>[4]</sup>效率对比,结果如表 3 所示。由表 3 可见,CNN1 在使用 CPU 的情况下测试完成原始图像平均用时为 704 ms·幅<sup>-1</sup>,CNN2 在使用 CPU 情况下平均用时均为 5 376 ms·幅<sup>-1</sup>。然而,采用 GPU 加速后 CNN1 用时为 192 ms·幅<sup>-1</sup>,CNN2 测试平均用时为 1 024 ms·幅<sup>-1</sup>,可见采用 GPU 加速更为高效。同时,GPU 加速 CNN 的效率较其他方法具有显著优势,CPU 模式下的 CNN 与其他方法效率基本一致。因此,CNN 图像检测效率基本满足要求。

#### 3.2 CNN 精度分析

采用不同分辨率样本训练并测试 CNN,结果如图 12 所示。由图 12 可见:M 随图像分辨率的提升

表 3 算法效率对比

Tab. 3 Efficiency Comparisons of Different Algorithms

分辨率/ 像素	时间	CNN1	CNN2	SVM 法	中值 转换法	最小 代价法
300	训练用时/s	1 960	2 588			
	测试用 CPU 模式	11	21	10	19	20
	时/ms GPU 模式	3	5			
150	训练用时/s	1 806	2 503			
	测试用 CPU 模式	11	20	9	19	19
	时/ms GPU 模式	3	4			
100	训练用时/s	1 638	2 487			
	测试用 CPU 模式	10	20	9	18	18
	时/ms GPU 模式	3	4			
70	训练用时/s	1 518	2 332			
	测试用 CPU 模式	9	19	8	18	17
	时/ms GPU 模式	3	3			
50	训练用时/s	1 320	2 174			
	测试用 CPU 模式	7	18	8	17	16
	时/ms GPU 模式	2	3			
30	训练用时/s	1 219	2 032			
	测试用 CPU 模式	7	16	6	15	16
	时/ms GPU 模式	2	3			

显著下降,所以图像分辨率越高,CNN 准确率就越高,当图像分辨率低于 70 像素时,CNN 的识别和特征提取精度明显下降,因此未来检测中图像分辨率应尽可能保证高于 70 像素。同时当图像分辨率大于 150 像素时,分辨率对 CNN 的识别精度影响不






图 12 不同分辨率计算结果

Fig. 12 Calculation Results of Different DPIs

再显著。

将 CNN 精度与其他方法<sup>[3-4,6]</sup>进行对比,结果如表 4 所示。由表 4 可知:识别 CNN1 较 SVM 法错误率降低了 0.8%~3.93%。裂缝特征提取 CNN2 较中值转换和最小代价法长度识别错误率降低了 1.09%~1.24%。在图像分辨率一定的情况下,CNN 较上述算法具有一定的精度优势。

表 4 算法误差率对比

分辨率/ 像素	不同方法的病害 识别错误率/%		不同方法的裂缝 长度误差/%		
	CNN1	SVM 法	CNN2	中值转换法	最小代价法
300	0.74	4.67	4.25	5.49	5.30
100	1.99	5.74	5.57	6.65	6.74
70	3.68	6.63	6.42	7.83	8.71
50	6.22	7.02	8.92	9.25	10.01
30	10.57	9.64	10.68	10.91	12.91

4 结 语

(1)CNN1 可以直接将路面图像作为输入样本,避免了图像预处理这一复杂的过程。训练完成后的 CNN1 可以直接对图像中的特征进行提取和判断,获得病害类型和病害几何特征信息,无需辅助操作。同时,CNN1 的识别、计算精度足以应对路面裂缝、坑槽病害的复杂形态特性。此外,CNN1 可实现裂缝与坑槽病害的识别与计算的高度自动化,可大幅提高病害检测速率。

(2)一个合理的 CNN 的搭建应包含数据输入、结构设计、样本训练、精度测试等步骤,确认其精度满足检测要求后,方可投入使用。CNN2 的精度为:裂缝长度提取平均误差为 4.27%,宽度提取平均误差为 9.37%,裂缝病害等级判断准确率为 98.99%。每张图片上 CNN 坑槽个数特征提取不存在误差,单个坑槽面积计算平均误差为 13.43%,坑槽病害等级断定准确率为 95.32%。可见,CNN2 具有较

高的测量精度和效率。

(3)CNN 在 GPU 加速下效率具有显著优势,在 CPU 计算模式下与其他算法基本一致。当图像分辨率低于 70 像素时,CNN 的识别和特征提取精度下降明显。在同等分辨率情况下,CNN 的识别和特征提取精度较其他具有一定的优势。

(4)本文仅对路面裂缝和坑槽病害进行了识别和部分特征的提取与测量。今后的研究应赋予神经网络更多的可识别病害类型;另一方面,本文无法提取坑槽深度等三维特征,未来应引入三维 CNN,实现病害三维特征的提取,以期为路面养护提供更为精准、全面的数据支撑。

参考文献:

References:

[ 1 ] TOSHIHIKO F,KEIJI T,MAKOTO N,et al. Automatic Pavement-distress-survey System[J]. Journal of Transportation Engineering,1990,116(3):280-286.

[ 2 ] LUO W,LI L,WANG K. Automated Pavement Horizontal Curve Measurement Methods Based on Inertial Measurement Unit and 3D Profiling Data[J]. Journal of Traffic and Transportation Engineering, English Edition,2016,3(2):137-145.

[ 3 ] 曹建农,张 昆,元 晨,等.用 Mean Shift 实现路面裂缝损伤自动识别与特征测量[J]. 计算机辅助设计与图形学学报,2014,26(9):1440-1459.

CAO Jian-nong,ZHANG Kun,YUAN Chen, et al. Automatic Road Cracks Detection and Characterization Based on Mean Shift[J]. Journal of Computer-aided Design & Computer Graphics,2014,26(9):1440-1459.

[ 4 ] 李清泉,邹 勤,毛庆洲.基于最小代价路径搜索的路面裂缝检测[J]. 中国公路学报,2010,23(6):28-32.

LI Qing-quan,ZOU Qin,MAO Qing-zhou. Pavement Crack Detection Based on Minimum Cost Path Searching[J]. China Journal of Highway and Transport,2010,23(6):28-32.

[ 5 ] LI Q,ZOU Q,ZHANG D. FoSA: F\* Seed-growing Approach for Crack-line Detection from Pvement Images [J]. Image and Vision Computing,2011,12(29): 861-872.

[ 6 ] 沈照庆,彭余华,舒 宁.一种基于 SVM 的路面影像损伤跨尺度识别方法[J]. 武汉大学学报:信息科学版,2013,38(8):993-997.

SHEN Zhao-qin,PENG Yu-hua,SHU Ning. A Road Damage Identification Method Based on Scale-span Image and SVM[J]. Geomatics and Information Sci-

- ence of Wuhan University, 2013, 38(8):993-997.
- [7] BARAT C, CHRISTOPHE D. String Representations and Distances in Deep Convolutional Neural Networks for Image Classification [J]. Pattern Recognition, 2016, 54:104-115.
  - [8] SHI B, BAI X, YAO C. Script Identification in the Wild Via Discriminative Convolutional Neural Network [J]. Pattern Recognition, 2016, 52:448-458.
  - [9] LENG B, GUO S, ZHANG X, et al. 3D Object Retrieval with Stacked Local Convolutional Autoencoder [J]. Signal Processing, 2015, 112:119-128.
  - [10] XU J, LUO X, WANG G. A Deep Convolutional Neural Network for Segmenting and Classifying Epithelial and Stromal Regions in Histopathological Images [J]. Neurocomputing, 2016, 191:214-223.
  - [11] LECUN Y, BERNHARD B, BOTTOU L, et al. Handwritten Digit Recognition with a Back-propagation Network [J]. Neural Information Processing Systems, 1990, 75:396-404.
  - [12] LECUN Y, BENGIO Y, HINTON G. Deep Learning [J]. Nature, 2015, 521(7553):436-444.
  - [13] ZBONTAR J, LECUN Y. Stereo Matching by Training a Convolutional Neural Network to Compare Image Patches [J]. Journal of Machine Learning Research, 2016, 17:451-460.
  - [14] XU T, ZHU F, EDWARD K, et al. Dual Many-to-one-encoder-based Transfer Learning for Cross-dataset Human Action Recognition [J]. Image and Vision Computing, 2016, 55(2):127-137.
  - [15] EARNEST P, KRISHNA M. Human Action Recognition Using Genetic Algorithms and Convolutional Neural Networks [J]. Pattern Recognition, 2016, 59:199-212.
  - [16] JORDI M, ALBERTO A, ROBERTO P. Local Deep Neural Networks for Gender Recognition [J]. Pattern Recognition Letters, 2016, 70:80-86.
  - [17] JIA F, LEI Y, LIN J, et al. Deep Neural Networks: A Promising Tool for Fault Characteristic Mining and Intelligent Diagnosis of Rotating Machinery with Massive Data [J]. Mechanical Systems and Signal Processing, 2016, 72-73:303-315.
  - [18] TONG Z, GAO J, HAN Z, et al. Recognition of Asphalt Pavement Crack Length Using Deep Convolutional Neural Networks [J]. Road Materials and Pavement Design, <https://doi.org/10.1080/14680629.2017.1308265>.
  - [19] CHA Y, CHOI W, BUYUKOZTURK O. Deep Learning-based Crack Damage Detection Using Convolutional Neural Networks [J]. Computer-aided Civil and Infrastructure Engineering, 2017, 32:361-378.
  - [20] TONG Z, GAO J, ZHANG H. Recognition, Location, Measurement, and 3D Reconstruction of Concealed Cracks Using Convolutional Neural Networks [J]. Construction and Building Materials, 2017, 146:775-787.
  - [21] ZHOU S, SHEN W, ZENG D, et al. Spatial-temporal Convolutional Neural Networks for Anomaly Detection and Localization in Crowded Scenes [J]. Signal Processing: Image Communication, 2016, 47:358-68.
  - [22] FENG L, PO L, LI Y, et al. Integration of Image Quality and Motion Cues for Face Anti-spoofing: A Neural Network Approach [J]. Journal of Visual Communication and Image Representation, 2016, 38:451-460.
  - [23] HU Y, CHANG H, NIAN F, et al. Dense Crowd Counting from Still Images with Convolutional Neural Networks [J]. Journal of Visual Communication and Image Representation, 2016, 38:530-539.
  - [24] FAN H, ZHOU E. Approaching Human Level Facial Landmark Localization by Deep Learning [J]. Image and Vision Computing, 2016, 47:27-35.
  - [25] NIAN F, LI T, WANG Y, et al. Pornographic Image Detection Utilizing Deep Convolutional Neural Networks [J]. Neurocomputing, 2016, 210:283-293.
  - [26] ADRIANA T, ABDON D, MONICA B, et al. Prediction of Compressive Strength of Concrete Containing Construction and Demolition Waste Using Artificial Neural Networks [J]. Construction and Building Materials, 2013, 38:717-722.
  - [27] DONG Y, WU Y. Adaptive Cascade Deep Convolutional Neural Networks for Face Alignment [J]. Computer Standards & Interfaces, 2015, 42:105-112.
  - [28] FENG L, PO L, LI Y, et al. Integration of Image Quality and Motion Cues for Face Anti-spoofing: A Neural Network Approach [J]. Journal of Visual Communication and Image Representation, 2016, 38:451-460.